

with perception

Created	@August 30, 2025 1:18 PM
Class	paper

Learning robust perceptive locomotion for quadrupedal robots in the wild

问题

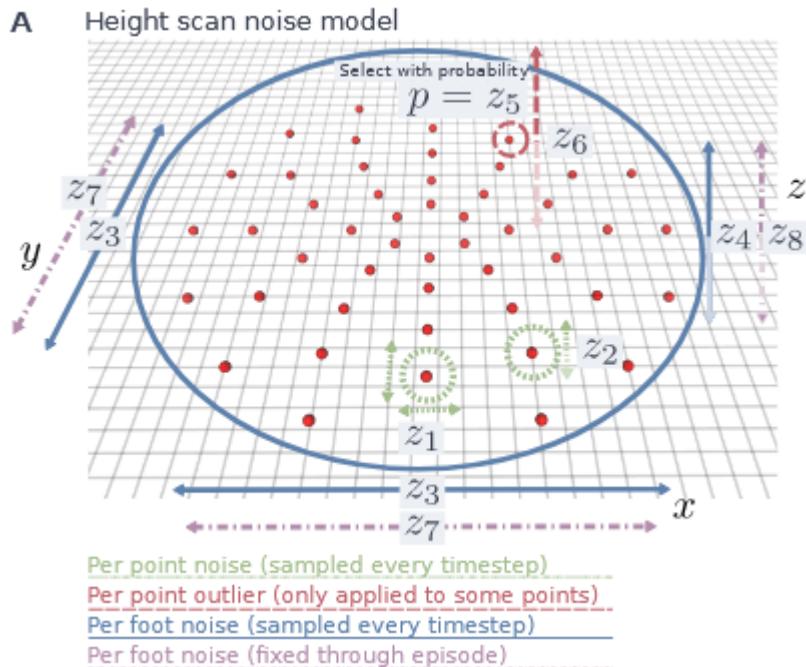
- 盲走：鲁棒，但是速度慢、效率低
- 纯外部感知：不够鲁棒
- 主要解决在真实环境下，如何鲁棒地利用外部感知信息的问题：
 - 反光地面或积雪：由于大多数深度传感器推断距离的方式，不好应对反射性或半透明的表面，可能出现沟壑或者没有数据
 - 地形表达局限：高程图是2.5D, 没办法表示悬垂物体（树枝）
 - 地形性质无法感知：无法区分柔软、坚硬的表面
 - 位姿估计漂移：在湿滑或可变性地面上行走时，估计的自身位姿会出现巨大误差
 - 传感器视角遮挡：由于机器人身体遮挡，导致地图信息不完整



perception运用方法

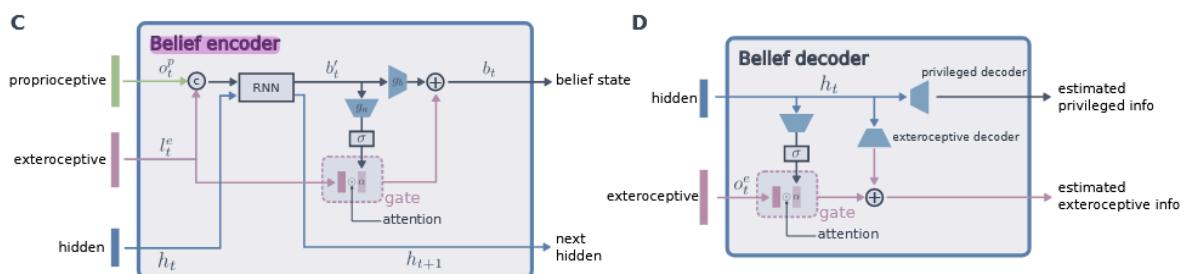
原始传感器数据输入→抽象层→控制策略网络：

1. **原始数据采集**：机器人使用板载的深度传感器（激光雷达和主动立体相机）获取周围环境的点云数据。
2. **构建Elevation Map**：系统将采集到的点云数据，结合机器人自身的位姿估计，融合成一个以机器人为中心的2.5D高程图。这一步将不同传感器的原始数据统一成了一种标准化的地形表示。
3. **地形采样 (Height Samples)**：控制策略网络并不使用整个高程图，而是在每个足端的周围，按照固定的几个同心圆模式采样一系列地形高度点（Height Samples）。这些离散的高度点构成了策略网络所需的**外部感知输入**。

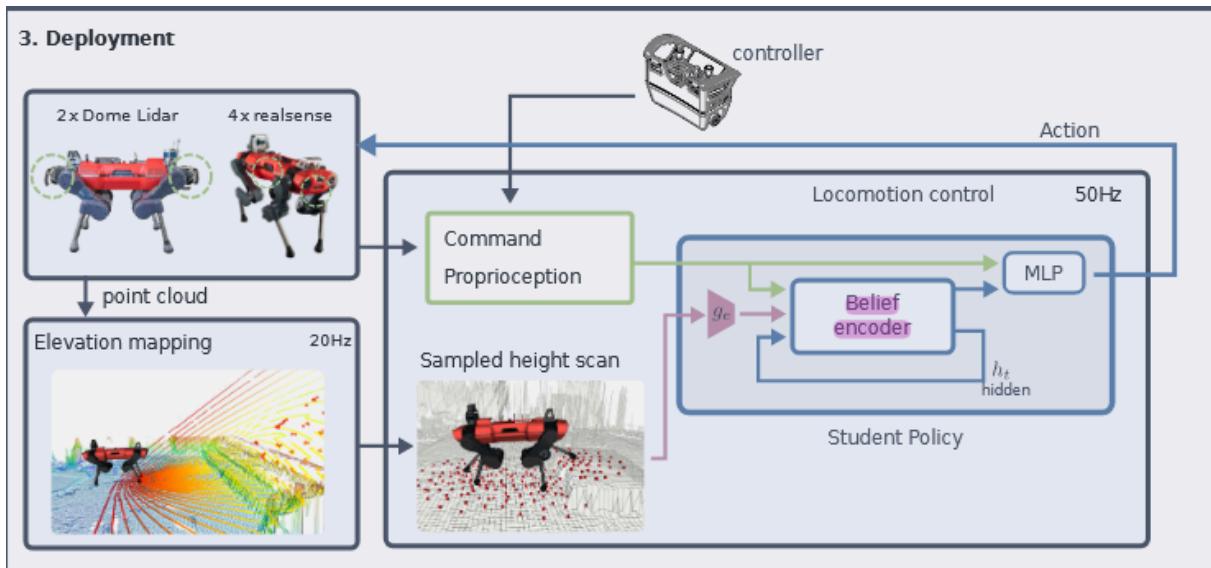


网络架构

- 功能：这个编码器接收当前的**本体感知信息**（关节状态、IMU数据等）和**外部感知信息**（地形高度采样点），并结合上一时刻的**隐藏状态**（记忆），生成一个对世界更完整的**Belief State**



- 实现：
 - GRU保留历史信息记忆
 - 门控机制**，网络可以学习到在不同情况下，应该给外部感知信息多大的权重。如果外部感知输入（高程图采样）与本体感知（实际接触感受）高度一致且稳定，门控会“打开”，让外部感知信息更多地流入信念状态，机器人因此可以快速预判地形。如果二者冲突（例如，踩到了一个传感器没看见的透明障碍物），网络会降低外部感知的权重，更多地依赖本体感知进行调整。
 - Teacher-Student Policy



可能方向

- 模拟传感器噪声，增加鲁棒性
- Teacher-Student框架
- 循环编码器结构
- 通过高程图作为中间表示，解耦感知模块和控制模块，分模块开发

Omni-Perception: Omnidirectional Collision Avoidance for Legged Locomotion in Dynamic Environments

核心

- 这篇论文的核心目标是让腿式机器人在复杂、动态的3D环境中实现**全向的 (omnidirectional)** 碰撞规避。
- 与许多依赖中间地图（如高程图）的方法不同，该研究提出了一个**端到端 (end-to-end)** 的学习框架**Omni-Perception**，它能够**直接处理原始的激光雷达 (LiDAR) 点云数据**来生成控制指令。

问题

该论文主要解决了现有感知运动方法的几大痛点：

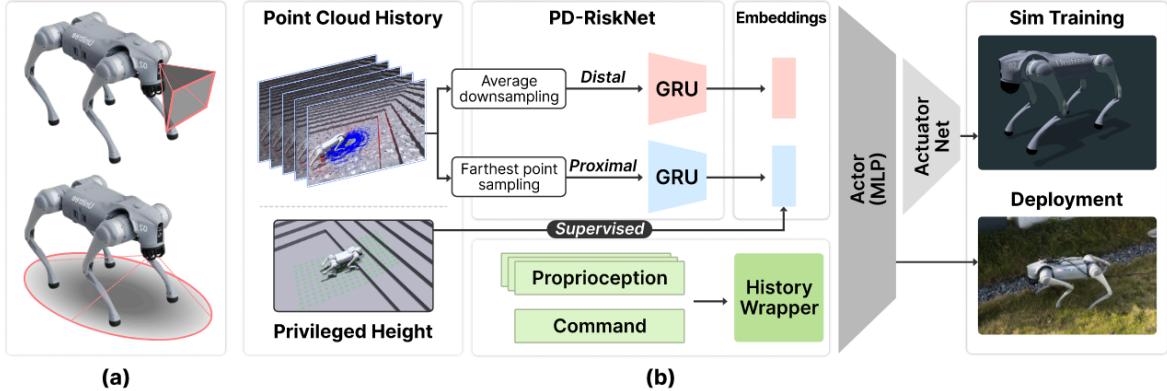
- **深度相机的局限性**：受光照条件影响，视场角有限，且容易受传感器噪声干扰
- **中间表征的计算开销与信息损失**：将传感器数据处理成高程图（elevation maps）等中间表征，会带来额外的计算开销。2.5D的地图无法有效表达空中悬挂物或复杂的非平面障碍。
- **对动态和全向威胁的反应迟缓**：传统的“plan-control”分离式方法通常导致机器人行为保守，无法充分发挥其运动的敏捷性。而已有的端到端方法大多是面向前方地形，缺乏对来自侧方、后方或空中的威胁进行快速反应的能力。
- **LiDAR在端到端学习中应用不足**：因为实时处理高维点云数据的计算挑战，LiDAR在腿式机器人端到端学习中的应用却很少，以及**缺乏高保真、高效率的LiDAR仿真器**来进行有效的“仿真到现实（sim-to-real）”训练。

运用

Omni-Perception框架采用了一种非常直接的感知信息流，核心是名为

PD-RiskNet的感知网络：

1. **直接输入原始点云**：策略的输入是历史N帧的原始LiDAR点云数据序列 (P_t)，而非任何处理过的地图。
2. **分区域处理（Proximal-Distal Partitioning）**：PD-RiskNet首先根据**垂直角度**将输入的原始点云 (P_{raw}) 分为两个部分：
 - **近端点云（Proximal Point Cloud, $P_{proximal}$ ）**：代表机器人近场的环境，点云密度高，对腿部运动和局部地形至关重要。
 - **远端点云（Distal Point Cloud, P_{distal} ）**：代表远场的环境，点云较稀疏，用于捕捉远处的障碍物和整体环境结构。
3. **分路径特征提取**：
 - **近端路径**：为了高效处理高密度的近端点云，网络采用Farthest Point Sampling来获取一个有代表性的稀疏子集。然后，这个子集被送入一个专门的GRU网络，用于提取与局部地形风险相关的时空特征。
 - **远端路径**：对于稀疏的远端点云，网络采用Average DownSampling来获得更均匀的表示并减少异常值影响。降采样后的点云序列同样被送入另一个独立的GRU，用于提取远处环境的动态上下文特征。
4. **特征融合与输出**：两条路径提取出的特征嵌入（Embeddings）与机器人的本体感知历史信息和任务指令（如目标速度）相结合，最终输入到一个MLP（多层感知机）执行网络（Actor），输出关节的目标位置。



locomotion

带规避的速度跟踪奖励 (r_{vel_avoid})。

- 它不仅仅是让机器人跟踪外部给定的速度指令 (v_{cmd})
- 它会根据LiDAR实时检测到的障碍物，动态计算一个规避速度向量 (V_{avoid})。这个向量会主动将机器人推离附近的障碍物。
- 奖励函数鼓励机器人去跟踪“指令速度 + 规避速度”的合速度。这样一来，规避行为被内生地融入到了运动目标中，使得规避动作更加自然和主动。

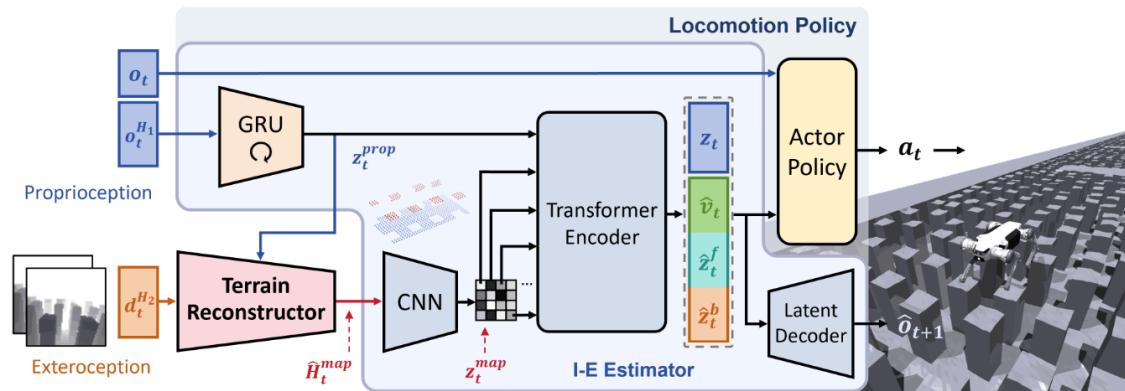
LIDAR SIMULATOR

LiDAR Simulation Feature	Ours	Isaac Sim	Gazebo
Rotating LiDAR Support	✓	✓	✓
Solid-State LiDAR Support	✓	✓	✓
Hybrid Solid-State LiDAR (Non-repetitive scan)	✓	✗	✓
Static Irregular Objects	✓	✓	✓
Dynamic Irregular Objects	✓	✗	✗
Self-Occlusion	✓	✗	✗
Cross-Platform Support	✓	✗	✓
Massively Parallel Execution	✓	✓	✗

Walking with Terrain Reconstruction: Learning to Traverse Risky Sparse Footholds

主要工作

- a single-stage end-to-end learning framework, 仅使用 proprioception 和 view-limited egocentric vision
- 地形重建器模块，以准确地重建当地地形，提供明确的监督目标，鼓励该政策全面提取和记住外部感受性信息，从而代表基本的地形特征
- sim2real稀疏立足点挑战，例如踏上石头，平衡梁，踏板梁和间隙
- 将局部地形重建作为一种中间表征。即，先用模块从有限的视觉信息中学习重建出一个机器人周围的局部高程图，然后再将这个清晰、结构化的高程图输入给运动策略网络。这个方法旨在融合上述两种思路的优点。



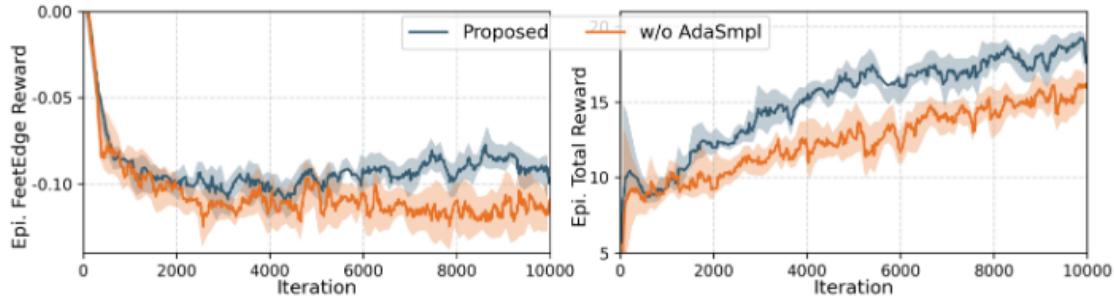
locomotion

- 输入：不直接使用深度图像，的外部感知输入是地形重建模块生成的高程图 (H_t^{map})，并结合当前的本体感知信息 (o_t)。
- 处理：它使用一个CNN来编码高程图，并用Transformer编码器融合多模态信息，最终生成动作。

rewards

应对桩子：

- 引入 **footedge reward**



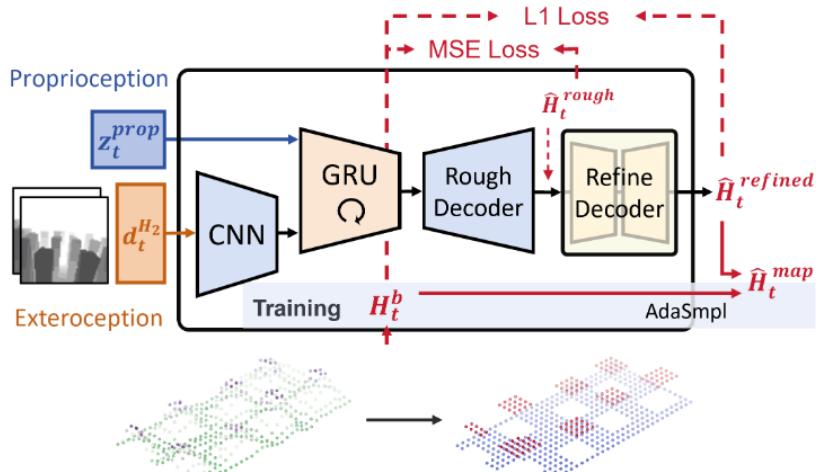
参考论文配置如黄色注释

TABLE I: Detail reward terms.

Reward Term	Equation	Weight
Lin. vel. tracking	$\exp(-\ \min(v, v^{\text{cmd}}) - v^{\text{cmd}}\ ^2 / 0.25)$	1.5
Ang. vel. tracking	$\exp(-\ \omega_{\text{yaw}} - \omega_{\text{yaw}}^{\text{cmd}}\ ^2 / 0.25)$	0.5
Lin. vel. (z)	v_z^2	-2.0
Ang. vel. (xy)	$\ w_{\text{xy}}\ ^2$	-0.05
Orientation	$g_x^2 + g_y^2$	-1.0
Torques	$\sum_{j \in \text{joints}} \tau_j ^2$	-1.0×10^{-5}
Action rate	$\sum_{j \in \text{joints}} a_t - a_{t-1} ^2$	-0.01
Smoothness	$\sum_{j \in \text{joints}} a_t - 2a_{t-1} + a_{t-2} ^2$	-0.01
Joint power	$\sum_{j \in \text{joints}} \tau_j q_j $	-2.0×10^{-5}
Joint accelerations	$\sum_{j \in \text{joints}} \ddot{q}_j ^2$	-2.5×10^{-7}
Joint error	$\sum_{j \in \text{joints}} q_j - q_j^{\text{default}} ^2$	-0.01
Collision	$\sum_{i \in \text{contact}} \mathbf{1}\{F_i > 0.1\}$	-10.0
Stumble	$\mathbf{1}\{\exists i, F_i^{\text{xy}} > 4 F_i^z \}$	-1.0
Feet edge	$\sum_{i \in \text{feet}} c_i \cdot \sum_{d \in \text{dist}} \omega_d E_d[p_i]$	-1.0

terrain reconstructor

- **输入**：它接收机器人历史2帧的原始深度图像 ($d_{t^{\text{H2}}}$) 和包含运动状态的**本体感知特征** ($z_{t^{\text{prop}}}$)。
- **处理**：它使用CNN提取视觉特征，并与本体特征融合，然后通过一个带记忆功能的GRU网络来处理时序信息。这个GRU至关重要，因为它能**记忆已经移出相机视野的地形**，从而重建出机器人身体下方和后方的区域。
- **输出**：最终输出一个**重建的局部高程图** ($H_{t^{\text{map}}}$)。这个高程图覆盖了机器人前方1.1米到后方0.5米的区域，分辨率为5厘米。



创新点

1. 以地形重建为桥梁的端到端框架

架构：端到端框架内部学习生成高程图

- **作为监督信号**：地形重建任务为视觉编码器提供了**物理意义明确的监督目标**。这迫使网络必须从稀疏的深度图中学会提取和理解关键的几何特征（如边缘），而不是模糊地学习。
- **作为清晰的表征**：重建后的高程图为运动策略提供了**结构化的、特征清晰的外部感知**，极大地降低了策略学习的难度。

2. 带记忆和精炼的地形重建器

- **记忆能力**：通过GRU网络整合时序信息和本体运动状态，实现了对相机视野外（身体下方和后方）地形的记忆和重建。
- **两阶段精炼**：重建过程分为“粗略重建”和“精炼”两步。精炼阶段使用了一个U-Net结构，专门用于消除噪声，使重建出的地形**边缘更清晰、表面更平坦**，这对于精确落足至关重要。

3. “自适应采样”与“地形渐进”的高效训练策略

为了解决稀疏奖励下的训练难题，作者提出了两种课程学习（Curriculum Learning）策略：

- **AdaSmpl**：在训练初期，重建器效果不好，输出的高程图噪声很大。此时，系统会以一定概率直接将“**真实的**”标准答案高程图喂给运动策略。这个概率会根据训练效果动态调整，帮助策略在早期快速稳定学习。

- **地形渐进课程 (Terrain Progressive Curriculum)**：机器人不是一开始就在最难的地形上训练，而是先在随机性较低的梅花桩上学习基本行走能力，然后逐步过渡到更难、更稀疏、更随机的地形。

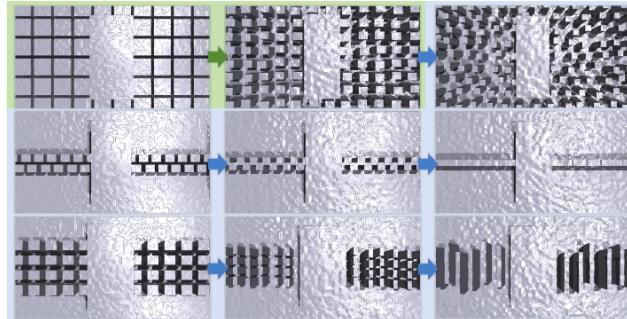


Fig. 4: The robots learn basic locomotion skills on the lower-randomness stepping stones (light green) at start, and are progressively transitioned to more challenging terrains with sparse footholds (light blue).

4. 针对精准落足的奖励函数

奖励函数中加入了一个专门的惩罚项 `(feetedge)`

启示

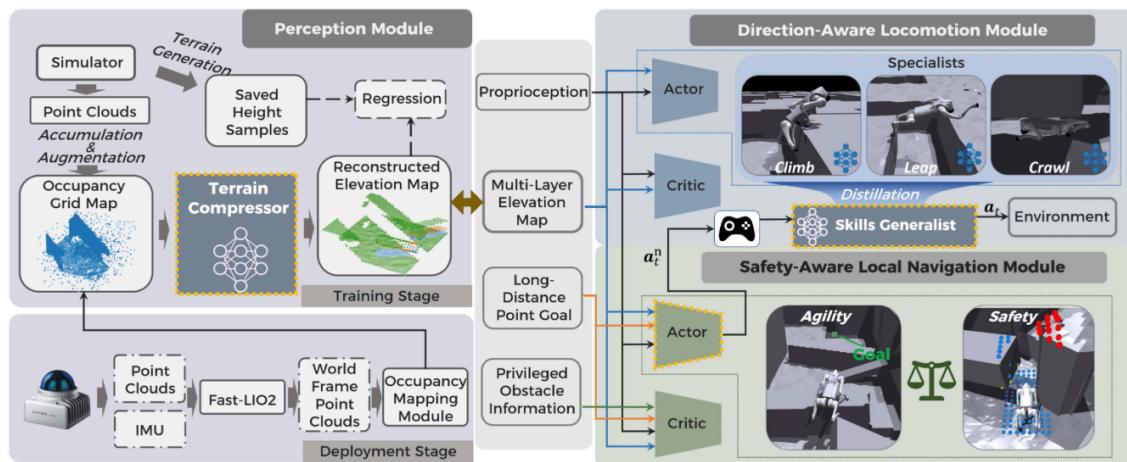
1. **中间表征**：当端到端的直接学习（从像素到动作）因为信息稀疏而变得困难时，引入一个可学习的、结构化的中间表征（高程图）是一个非常有效的降维和解耦方法。
2. **重建作为一种强大的自监督/监督信号**：可以将“重建”作为一个辅助任务来训练你的视觉编码器，可以极大地提升它对几何特征的理解能力
3. **课程学习是解决难题的关键**：面对奖励稀疏、探索困难的任务，可以设计课程学习（如AdaSmpI和地形递进）
4. **奖励函数要与任务目标紧密对齐**：`feetedge` 奖励项，将具体的物理约束（不要踩边缘）直接反映在奖励函数中

Learning Autonomous and Safe Quadruped Traversal of Complex Terrains Using Multi-Layer Elevation Maps

工作

- 引入了新颖和简洁的地形表示，以涵盖各种场景，neural terrain compressor使其适用于现实世界中的环境。
- 提出了一个分层导航系统，使四足动物的机器人在混乱的环境中安全地自动移动。
- 精心设计的地形和奖励用于增强政策的概括和机动性。
- 多层高程图 (multi-layer elevation map):捕获悬垂障碍物和神经地形压缩机

METHOD



为了让这两个策略能够理解带有悬垂物 (overhanging obstacles) 的复杂环境，作者提出了一个核心创新：

多层高程图 (Multi-Layer Elevation Map) 作为一种新的地形表征方式。为了将这种理想化的地图应用于现实世界，他们还训练了一个神经网络地形压缩器 (neural terrain compressor)，负责将真实传感器 (LiDAR) 产生的嘈杂的、不完整的占据栅格图 (occupancy grid map) 转换成干净的多层高程图。

运用

这篇论文的感知流程非常精巧，将感知处理与策略训练进行了解耦，分为仿真训练和真实部署两个阶段：

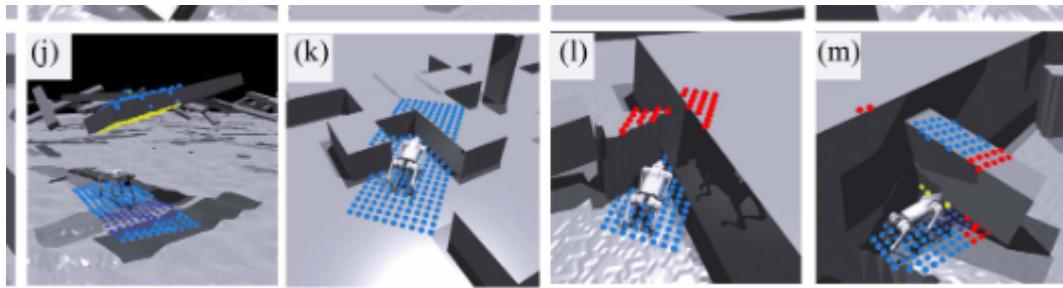
1. 感知表征：多层次高程图 (Multi-Layer Elevation Map)

- 这是一种对传统高程图的扩展。本文中被简化为**3层**。
- 第1层表示地面高度。**
- 第2层和第3层分别表示其上方第一个悬垂物的底面和顶面高度。**

- 如果没有悬垂物，三层的高度值就相同，此时它就等价于一个标准的单层高程图。
- 这种设计既能表示复杂结构，又保持了高程图的数据高效性。

2. 感知模块核心：神经网络地形压缩器 (Neural Terrain Compressor)

- 这是一个**独立训练**的轻量级UNet网络。
- **功能**：它的任务是将一个标准的、充满噪声和空洞的**占据栅格图**作为输入，然后输出一个干净、完整的**3层高程图**。
- **训练**：研究者在Gazebo仿真中采集大量数据对（占据栅格图 vs. 真实3层高程图）来训练它，并加入了随机清除点云、注入噪声等数据增强手段以提升其泛化能力。
- **作用**：将真实世界中标准建图模块（如Fast-LIO2）输出的“脏数据”转换成了策略网络能够理解的“标准格式”。



locomotion

$$r_{\text{vel_tracking}} = \exp \left(-\frac{1}{\sigma} (\mathbf{v}_{xy} - \mathbf{c}_{xy})^2 \right) \frac{\cos(\theta_{\text{error}}) + 1}{2}, \quad (3a)$$

$$\theta_{\text{error}} = |\theta - \theta_{\text{target}}|, \quad (3b)$$

sim2real高程图效果

